
LABORATORIO DE DATOS

Primer Cuatrimestre 2026

Trabajo Práctico

El Trabajo Práctico deberá ser resuelto en grupos tres personas (o excepcionalmente, dos personas). No se aceptarán entregas individuales. La entrega se realizará a través del campus (pestaña Trabajos Prácticos). La fecha límite es el 24/06 a las 23:59. Deben entregar un Notebook con los nombres de los integrantes del equipo, la resolución de los ejercicios y los informes pertinentes.

Se valorará que el Notebook y el código tengan un formato prolijo: ejercicios separados por títulos (Ejercicio 1, Ejercicio 2, etc.), nombres descriptivos para las variables, comentarios, etc.

En este trabajo práctico el objetivo es utilizar las herramientas vistas en clase para analizar las selecciones del mundial de fútbol 2026, y armar un 11 ideal para algunos países.

Para esto usaremos un dataset con datos de los jugadores convocados por cada selección y datos estadísticos de los jugadores tomados de distintas fuentes (principalmente FBRef y TransferMarket).

Limpieza y Procesamiento de Datos [2 pts.]

El dataset `jugadores.csv` contiene las estadísticas de los jugadores de cada selección, extraídos de las ligas domésticas en las que juega cada jugador. Según la liga en que juegan la información está mas o menos completa. La primera parte de este TP es armar un dataset limpio que contenga la misma información para todos los jugadores.

Para contestar las distintas preguntas utilizar comandos apropiados de Python y Pandas.

1. Cargar en un DataFrame `df_jugadores` los datos del archivo `jugadores.csv`.
2. Resumiendo datos:
 - a) Contar cuántos jugadores tenemos por cada selección. ¿Hay la misma cantidad de jugadores para todas las selecciones? ¿Cuáles son las selecciones con menos jugadores convocados?
 - b) Mostrar los clubes con al menos 10 jugadores convocados al Mundial.
 - c) Agregar la columna `rango_etario` tal que si el jugador tiene menos de 24 años, su rango etario sea 'A'; si tiene entre 24 y 30 años sea 'B'; si tiene 31 años o más, sea 'C'. ¿Cuál es el rango etario dominante en las primeras cinco selecciones del Ranking FIFA?

3. Hay distintos grupos de variables, algunos de estos grupos solo están disponibles para jugadores de las ligas europeas y vamos a eliminarlos. Elegir una variable de cada uno de los siguientes grupos: `standard_`, `shooting_`, `misc_performance_`, `playing_time_` y analizar cuántos jugadores tienen esa información. Eliminar los grupos de variables que tengan cobertura menor al 60 % (es decir que solo estén disponibles para menos del 60 % de los jugadores).
4. Dentro del grupo `shooting_` hay variables de ratios que solo se calculan cuando el jugador hizo tiros, y están NA en otros casos, ¿cómo podemos tratar los NA en este caso para no eliminar la variable?
5. ¿Cómo analizan la variables del grupo `keeper_`? ¿Qué cobertura tienen y a qué se puede deber? ¿Cómo lo podemos solucionar sin eliminar las columnas?
6. En base a lo trabajado en las preguntas anteriores, armar una base `df_jugadores_limpia` sin datos faltantes (deben quedar al menos 30 variables numéricas y al menos 850 jugadores).
7. A partir de `df_jugadores_limpia` armar una base de datos `df_selecciones` que contenga solo la columna `seleccion` y las variables numéricas tomando el promedio de cada variable numérica para los jugadores de cada selección. Eliminar primero a las selecciones con 4 o menos jugadores con datos (luego de limpiar columnas y filas con datos faltantes).

Pueden incorporar también información de algunas variables categóricas construyendo dummies apropiadas, por ejemplo construir una variable que indique si cada jugador juega en alguna liga europea (confederación UEFA) y a partir de esa variable obtener para cada selección el porcentaje de jugadores que juegan en Europa.

Análisis exploratorio [2pts.]

Esta sección es libre para que planteen una o dos preguntas que les genere interés y realicen un análisis exploratorio de los datos, aplicando las herramientas de visualización (`seaborn.objects`, `seaborn` y/o `matplotlib`) y de resumen de datos (media, mediana, desvío estándar, operaciones sobre el DataFrame, etc.).

Algunas preguntas disparadoras (pueden usar estas mismas preguntas u otras que les genere interés):

- ¿Hay diferencias importantes entre las selecciones europeas y las selecciones sudamericanas? ¿Cambia la respuesta si consideramos a las selecciones más importantes de cada región o consideramos a todas las selecciones?
- ¿Podemos identificar distinto tipo de juego en distintas selecciones? (más defensivas, más ofensivas, más jóvenes, etc...)

O algunas preguntas que requieran consultar otras fuentes además de las estadísticas de jugadores:

- ¿Que selecciones tuvieron mayor renovación del mundial anterior a este?
- ¿Este mundial genera mas o menos interés que mundiales anteriores?
- ¿Se reduce el rendimiento académico de los estudiantes durante los Mundiales de Fútbol?

En el Notebook, las visualizaciones y resúmenes de datos que realicen deben estar acompañados por las conclusiones que obtengan a partir de ellos.

PCA y Clustering [2pts.]

El objetivo en esta sección es identificar grupos de selecciones con características similares.

1. Escalar los datos y realizar un análisis de componentes principales, quedándose solo con las dos primeras componentes. Realizar un gráfico de dispersión de la segunda componente en función de la primera para el total de las observaciones. ¿Pueden encontrar fácilmente grupos distintos?
2. ¿Cuáles variables tienen más peso en la primera componente y cuáles tienen más peso en la segunda variable? ¿Pueden darle alguna interpretación a cada componente?
3. Elegir un método de clustering visto en clase que consideren apropiado para este problema, determinar los hiperparámetros mediante los métodos vistos y realizar el agrupamiento (para el agrupamiento utilizar todas las variables numéricas escaladas, no solo las dos primeras componentes principales).
4. En el gráfico anterior colorear a las selecciones según el clustering obtenido. ¿Coinciden aproximadamente el agrupamiento con la ubicación de los puntos en la visualización? A partir de esta respuesta, ¿considera que las dos primeras componentes resumen satisfactoriamente la información en la base? Calcular el porcentaje de varianza total explicada por las dos primeras componentes y ver si concuerda con la respuesta de la pregunta anterior.
5. Interpretar alguno de los clusters en base a las variables que los diferencian. Por ejemplo, un cluster con selecciones con jugadores jóvenes o jugadores caros o selecciones con buena defensa.

Regresión y clasificación [3pts.]

En esta sección queremos detectar jugadores que estén jugando en una posición que no es la natural por sus características o que no están teniendo en sus equipos todos los minutos de juego que se merecen.

1. Generar un DataFrame `df_jugadores_regresion` agregando a `df_jugadores_limpia` una variable de minutos jugados / 90 minutos, dividiendo el total de minutos jugados por el jugador por la cantidad total de partidos de la liga correspondiente (para estimar el total de partidos analizar el maximo de partidos jugados por los jugadores de cada confederación).
2. **Regresión.** Realizar un modelo de regresión para predecir la cantidad de minutos jugados / 90 minutos por cada jugador al partir de las demás variables numéricas (excluir todas las variables de cantidad de partidos jugados y minutos jugados). Para armar el modelo, proponer dos modelos distintos y elegir el mejor por algún esquema de validación.
3. **Clasificación.** Realizar un modelo de clasificación por KNN para predecir la posición en la que juega cada jugador Elegir el K óptimo por algún esquema de validación.

En la tabla de jugadores tenemos dos variables de posición: `posicion` proveniente de Wikipedia y `posicion_tm` proveniente de Transfer Market. ¿Qué diferencia hay entre las dos variables? ¿Cuál será más fácil de predecir? Pueden predecir cualquiera de las dos variables para clasificar a los jugadores (o armar una nueva variable agrupando posiciones similares). Al hacer las predicciones, no usen la otra variable como variable explicativa.

El 11 ideal de Argentina y Brasil [1pt]

Para armar el 11 ideal de cada país, queremos seleccionar 1 arquero, 4 defensores, 4 mediocampistas y 2 atacantes entre los jugadores de cada país. Vamos a utilizar las posiciones predichas en la sección anterior para determinar la posición de cada jugador y la variable minutos jugadores predicha para elegir en cada posición al jugador con mas minutos.

Armar el 11 de ideal de Argentina y Brasil siguiendo estas indicaciones. Considerar el 11 inicial del partido Argentina-Argelia y comparar esa selección con la selección armada por nuestro modelo.